

## 宇宙輸送機非破壊検査のための赤外線応力測定と機械学習に基づく CFRP 欠陥推定

村松研究室 学部 4 年 佐藤瑞起

## 1 研究背景・目的

## 1.1 CFRP の宇宙輸送機器への応用

炭素繊維強化プラスチック (carbon-fiber-reinforced plastics, CFRP) は、高比剛性・軽量性という利点から宇宙輸送機器の主要構造への適用が拡大している。特に段間構造や衛星フェアリングのような大規模・複雑形状の構造では、運用段階での健全性評価を短時間かつ高信頼に実施できる検査基盤が、再使用化と低コスト化の要求の下で求められる。一方で、CFRP は層間剥離などの内部損傷が表面観察のみでは把握しにくく、従来手法だけで効率的に健全性を保証することには限界がある [1]。

## 1.2 非破壊検査と先行研究

宇宙輸送機器の非破壊検査では打音検査や超音波測定が広く用いられてきたが、検査コストと運用時の迅速性に改善余地がある [1]。これに対して赤外線応力測定は、繰り返し荷重下の表面温度変化から表面主応力和分布 (DSPSS) を取得できる非接触計測として注目されている [2]。DSPSS と機械学習を組み合わせた欠陥推定の先行研究は、方法論で以下の二系統に整理できる。

第一に、畳み込みニューラルネットワーク (CNN) を用い、FEM 由来 DSPSS による事前学習と赤外線応力測定データによるファインチューニングを組み合わせる二段階転移学習が提案されており、シミュレーション・実験間のドメインギャップ低減に有効である一方、対象は単純短冊形状に限定される [3]。第二に、グラフニューラルネットワーク (GNN) を用いることで、CNN が前提とする格子状入力では扱いにくい不規則メッシュや穴あき形状の試験片に対しても欠陥推定が可能となるが、検証は FEM データのみで行われており実験データとの統合は未着手である [4, 5]。

## 1.3 研究ギャップと本研究の目的

以上から、本研究領域には方法論的・応用的な空白が残されている。方法論的には、GNN ベース欠陥推定と二段階転移学習を組み合わせる枠組みが未整備であり、両系統の長所を統合した上での FEM-実験間ドメインギャップ低減手法と評価が確立されていない。応用的には、検証対象が単純形状・穴あき試験片までに留まり、宇宙輸送機器を意識した形状条件下での実験統合型検証が十分に行われていない。

そこで本研究では、GNN による不規則メッシュ対応の欠陥推定モデルに、FEM 由来 DSPSS 事前学習と赤外線応力測定データによる適応の二段階転移学習を組み合わせ、宇宙輸送機器の非破壊検査に資する CFRP 欠陥推定手法の構築を目的とする。

## 2 理論

## 2.1 赤外線応力測定

弾性域かつ断熱状態にある物体では、繰り返し荷重下で生じる主応力和の変化と表面温度変化が比例関係を持つ熱弾性効果が現れる。Kelvin の理論によれば、温度変化  $\Delta T$  と主応力和の変化量  $\Delta \sigma$  は次式の関係を満たす [2]。

$$\Delta T = -k T \Delta \sigma \quad (1)$$

ここで、 $T$  は絶対温度、 $k$  は熱弾性率である。熱弾性率は線膨張係数  $A$ 、密度  $\rho$ 、定圧比熱  $C_P$  を用いて  $k = A/(\rho C_P)$  と定義され、材料固有の物性値である。赤外線応力測定では、繰り返し荷重を加えながら赤外線カメラで取得した温度画像にロックイン処理を施し、環境ノイズや温度ドリフトの影響を抑えて応力に対応する温度変化成分のみを抽出する。このロックイン処理により、試験体表面の主応力和分布 (以下 DSPSS と呼ぶ) を非接触かつ広範囲に取得できる。

## 2.2 有限要素法

有限要素法は、連続体の応力解析を仮想仕事の原理に基づいて離散化する数値解析手法であり、複雑形状や不均質材料を含む構造解析に広く用いられる。現在配置  $B_t$  において、静的可容応力場  $\sigma$ 、仮想ひずみ  $\delta \varepsilon$ 、表面荷重  $t^0$ 、仮想変位  $\delta u$ 、密度  $\rho$ 、重力加速度  $g$  は次の関係を満たす。

$$\int_{B_t} \sigma : \delta \varepsilon dv = \int_{\partial B_t^c} t^0 \cdot \delta u ds + \int_{B_t} \rho g \cdot \delta u dv \quad (2)$$

左辺は  $B_t$  内部における内部仮想仕事、右辺は外力がなす外部仮想仕事を表し、両者の釣り合いから支配方程式が導出される。本研究では CFRP 積層板を有限要素メッシュに離散化し、欠陥を含む条件下での表面主応力和分布を解析的に取得することで、赤外線応力測定だけでは網羅しがたい欠陥配置パターンを補完する学習データとして用いる。

## 2.3 グラフニューラルネットワーク

グラフニューラルネットワーク (GNN) は、ノード集合  $\mathcal{V}$  とエッジ集合  $\mathcal{E}$  からなるグラフ  $\mathcal{G} = (\mathcal{V}, \mathcal{E})$  上で、隣接ノードからの情報を集約しながら節点特徴を更新するニューラルネットワークである。有限要素メッシュの節点・隣接関係をそのままグラフとして扱えるため、CNN が前提とする格子状入力の制約を持たず、不規則メッシュや段間構造・衛星フェアリングのような複雑形状にも適用できる [5]。代表的なグラフ畳み込みネットワーク (GCN) では、隣接ノードからの寄与を次数で正

規化したうえで線形変換と活性化を施すことで節点特徴を更新する [6].

$$z_i^{(l+1)} = \phi \left( \sum_{j \in N(i) \cup \{i\}} \frac{1}{\sqrt{\deg(i) \deg(j)}} W^{(l+1)} z_j^{(l)} \right) \quad (3)$$

ここで,  $z_i^{(l)}$  は  $l$  層目におけるノード  $i$  の特徴ベクトル,  $N(i)$  は  $i$  の隣接ノード集合,  $\deg(i)$  はノード  $i$  の次数,  $W^{(l+1)}$  は学習パラメータ,  $\phi$  は活性化関数である. 本研究では, CFRP 積層板の有限要素メッシュをグラフに変換し, 各節点の表面主応力を入力特徴量とすることで, 幾何学的制約を緩めた形で欠陥推定モデルを構築する.

### 3 方法

提案手法は, (i)FEM 由来 DSPSS, (ii) 赤外線応力測定由来 DSPSS, (iii) 欠陥ラベルの 3 要素を統合して学習を行う. まず FEM データを用いて基礎学習を行い, 次に赤外線応力測定データを用いて実験条件への適応を行う. この二段階設計により, シミュレーションデータの量的優位性と実験データの現実性を両立する. 入力 は表面主応力分布およびメッシュ関連情報, 出力は欠陥位置 (必要に応じて層情報を含む) とする. 評価は推定精度に加えて, ノイズ耐性, 実験条件変化に対する汎化性, および実験データとの整合性を確認する.

### 4 今後の予定

短期的には, 宇宙輸送機構造を対象にした解析条件の固定と, 赤外線応力測定データの前処理手順の確立を行う. 次に, FEM 事前学習モデルに対する実験データ適応を実施し, シミュレーション中心推定と実験統合推定の比較評価を進める. 最終的には, 宇宙輸送機非破壊検査への適用を意識した, 実験統合型欠陥推定手法としての妥当性を検証する.

### 参考文献

- [1] 横野泰和. 非破壊検査の種類と特徴. *溶接学会誌*, 59(6):410–413, 1990.
- [2] 阪上隆英. 赤外線サーモグラフィによる熱弾性応力測定 of 最近の進歩. *実験力学*, 1(3):120–126, 2001.
- [3] Kojima Y. Hirayama K. Endo K. Harada Y. Muramatsu M. Transfer-learning-aided defect prediction in simply shaped cfrp specimens based on stress distribution obtained from finite element analysis and infrared stress measurement. *Composites Part B: Engineering*, 291:111958, 2025.
- [4] 西岡 佳祐. グラフニューラルネットワークを用いた炭素繊維強化プラスチック製穴あき試験片の欠陥推定手法の開発. 慶應義塾大学 理工学部 機械工学科 2024 年度 卒業論文, 2025.
- [5] Horie M. Morita N. Ihara Y. and Mitsume N. Learning mesh-based numerical analysis using graph neural networks. *Transactions of JSCES*, arXiv:2010.03409,

2020.

- [6] Thomas N. Kipf. Max W. Semi-supervised classification with graph convolutional networks. *ICLR*, arXiv:1609.02907, 2017.