

宇宙輸送機非破壊検査のための赤外線応力測定と機械学習に基づく CFRP 欠陥推定

村松研究室 学部 4 年 佐藤瑞起

1 研究背景・目的

1.1 CFRP の宇宙輸送機器への応用

炭素繊維強化プラスチック (carbon-fiber-reinforced plastics, CFRP) は、高比剛性・軽量性から宇宙輸送機器の主要構造への適用が拡大している。特に段間構造や衛星フェアリングのような大規模・複雑形状では、運用段階での健全性評価を短時間かつ高信頼に行う検査基盤が、再使用化と低コスト化の要求下で求められる。一方で、CFRP は層間剥離などの内部損傷が表面観察のみでは把握しにくく、従来手法のみでの健全性保証には限界がある [1]。

1.2 非破壊検査と先行研究

宇宙輸送機器の非破壊検査では打音検査や超音波測定が広く用いられてきたが、検査コストと運用時の迅速性に改善余地がある [1]。これに対して赤外線応力測定は、繰り返し荷重下の表面温度変化から表面主応力分布 (Distribution of the sum of the principal stresses on the surface, DSPSS) を取得できる非接触計測として注目されている [2]。DSPSS と機械学習を組み合わせた欠陥推定の先行研究は、方法論で以下の二系統に整理できる。

第一に、畳み込みニューラルネットワーク (Convolutional Neural Network, CNN) を用い、有限要素法 (finite element method, FEM) 由来 DSPSS による事前学習と赤外線応力測定データによるファインチューニングを組み合わせる二段階転移学習が提案されているが、対象は単純短冊形状に限定される [3]。第二に、グラフニューラルネットワーク (Graph Neural Network, GNN) の利用により CNN が扱いにくい段間構造を模擬した曲面・穴あき形状の試験片にも欠陥推定を適用できるが、検証は FEM データのみで実験データとの統合は未着手である [4,5]。

1.3 研究ギャップと本研究の目的

以上から、本研究領域には方法論的・応用的な空白が残されている。方法論的には、GNN ベース欠陥推定と二段階転移学習を組み合わせる枠組みが未整備であり、両系統の長所を統合した上での FEM-実験間ドメインギャップ低減手法と評価が確立されていない。応用的には、段間構造を模擬した曲面・穴あき形状の試験片に対する検証が FEM 解析データに留まり、実験データを統合した欠陥推定の検証が行われていない。

そこで本研究では、GNN による不規則メッシュ対応の欠陥推定モデルに、FEM 由来 DSPSS 事前学習と赤外線応力測定データによる適応の二段階転移学習を組み合わせ、宇宙輸送機器の非破壊検査に資する CFRP 欠陥推定手法の構築を目的とする。

2 理論

2.1 赤外線応力測定

弾性域かつ断熱状態にある物体では、繰り返し荷重下で生じる主応力の変化と表面温度変化が比例関係を持つ熱弾性効果が現れる。Kelvin の理論によれば、温度変化 ΔT と主応力の変化量 $\Delta \sigma$ は次式の関係を満たす [2]。

$$\Delta T = -k T \Delta \sigma \quad (1)$$

ここで、 T は絶対温度、 k は材料固有の物性値である熱弾性率である。赤外線応力測定では、繰り返し荷重を加えながら赤外線カメラで取得した温度画像にロックイン処理を施すことで、環境ノイズや温度ドリフトの影響を抑え、試験体の DSPSS を非接触かつ広範囲に取得できる。

2.2 有限要素法

有限要素法は、内部仮想仕事と外部仮想仕事の釣り合いを表す仮想仕事の原理を弱形式の出発点として連続体の応力解析を離散化する数値解析手法であり、複雑形状や不均質材料を含む構造解析に広く用いられる。有限要素メッシュ上で支配方程式を解くことで、欠陥配置や荷重条件を変えた DSPSS を網羅的に取得でき、赤外線応力測定では確保しがたい学習データの多様性を補完できる。

2.3 グラフニューラルネットワーク

グラフニューラルネットワーク (GNN) は、グラフ上で隣接ノードからの情報を集約しながら節点特徴を更新するニューラルネットワークである。有限要素メッシュの節点・隣接関係をそのままグラフとして扱えるため、CNN が前提とする格子状入力の制約を持たず、不規則メッシュや複雑形状にも適用できる [5]。代表的なグラフ畳み込みネットワーク (GCN) では、隣接ノードからの寄与を次数で正規化したうえで線形変換と活性化を施すことで節点特徴を更新する [6]。

$$z_i^{(l+1)} = \phi \left(\sum_{j \in N(i) \cup \{i\}} \frac{1}{\sqrt{\deg(i) \deg(j)}} W^{(l+1)} z_j^{(l)} \right) \quad (2)$$

ここで、 $z_i^{(l)}$ は l 層目におけるノード i の特徴ベクトル、 $N(i)$ は i の隣接ノード集合、 $\deg(i)$ はノード i の次数、 $W^{(l+1)}$ は学習パラメータ、 ϕ は活性化関数である。

3 方法

本研究では、FEM 由来 DSPSS による事前学習と、赤外線応力測定により取得した DSPSS によるファイ




図 1: 提案する欠陥推定手法の全体フロー




図 2: 赤外線応力測定に用いる実験装置 [3]

ンチューニングを組み合わせた二段階転移学習 [3] を、GNN ベースの欠陥推定モデル [4] に適用する．提案手法の全体構成を図 1 に示す．

3.1 FEM 由来データの生成

学習データの DSPSS は、CFRP 積層板を有限要素メッシュに離散化し、欠陥を含む条件下で弾性解析を行うことで取得する．層間剥離はせん断応力が伝播しない状態を再現するため、剥離面を構成する節点に二重節点を割り当てて表現する [3]．荷重条件には赤外線応力測定を模した一方向引張を与え、欠陥の挿入位置・サイズ・挿入層を変えた多数の条件を設定する．取得した DSPSS には、赤外線応力測定で生じる熱ノイズを模倣した人工ノイズを付与する．

3.2 赤外線応力測定の実験条件

ファインチューニング用の DSPSS は、段間構造を模倣した曲面形状の CFRP 試験片に対する赤外線応力測定により取得する．試験片は一方向強化複合材を擬似等方に積層した構成とし、欠陥として層間にテフロンシートを挿入したものと挿入しないものを用意する．実験装置は疲労試験装置と赤外線カメラで構成され (図 2)、正弦波の繰り返し引張荷重を加えながら、2.1 で述べた手法で試験片の DSPSS を取得する．

3.3 GNN 欠陥推定モデルと二段階転移学習

欠陥推定モデルには、FEM メッシュの節点を頂点・要素隣接をエッジとしたグラフを入力とする GNN を用い、各節点の DSPSS を入力特徴量として欠陥クラス (あり/なし) と挿入層を推定する．学習は二段階で運用し、

第一段階では人工ノイズを付与した FEM 由来 DSPSS で GNN 全体を学習、第二段階では事前学習済みモデルに対し少量の赤外線応力測定 DSPSS で出力層側のパラメータを再学習する．評価には平面位置一致率と挿入層一致率を導入し、FEM のみで学習したモデルとの比較を通じて転移学習の効果を検証する方針とする．

4 今後の予定

今後は、段間構造を模倣した穴あき曲面形状試験片を対象とした赤外線応力測定実験を中心に研究を進める．まず、西岡らの研究 [4] で用いられた試験片設定を確認し、欠陥の位置・種類および試験片形状を検討したうえで、実験に用いる試験片を設計する．設計後は、計測に向けた試験片の作製と準備を行い、JAXA での赤外線応力測定実験を予定している．取得した実験データに 3 章で述べた二段階転移学習を適用し、欠陥の平面位置一致率と挿入層一致率により推定精度を評価する．

参考文献

- [1] 横野泰和．非破壊検査の種類と特徴．*溶接学会誌*, 59(6):410–413, 1990.
- [2] 阪上隆英．赤外線サーモグラフィによる熱弾性応力測定 of の最近の進歩．*実験力学*, 1(3):120–126, 2001.
- [3] Y. Kojima, K. Hirayama, K. Endo, Y. Harada, and M. Muramatsu. Transfer-learning-aided defect prediction in simply shaped cfrp specimens based on stress distribution obtained from finite element analysis and infrared stress measurement. *Composites Part B: Engineering*, 291:111958, 2025.
- [4] K. Nishioka, Y. Kojima, T. Saito, K. Kawakami, T. Washiya, and M. Muramatsu. Development of defect localization method for perforated carbon-fiber-reinforced plastic specimens using finite element method and graph neural network. *Frontiers in Materials*, 12:1652484, 2025.
- [5] M. Horie, N. Morita, Y. Ihara, and N. Mitsume. Learning mesh-based numerical analysis using graph neural networks. *Transactions of JSCES*, arXiv:2010.03409, 2020.
- [6] Thomas N. Kipf and Max Welling. Semi-supervised classification with graph convolutional networks.

ICLR, arXiv:1609.02907, 2017.