

宇宙輸送機非破壊検査のための赤外線応力測定と機械学習に基づく CFRP 欠陥推定

村松研究室 学部 4 年 佐藤瑞起

1 研究背景・目的

1.1 CFRP の宇宙輸送機器への応用

炭素繊維強化プラスチック (CFRP) は、高比剛性・軽量性という利点から、宇宙輸送機器の主要構造への適用が拡大している。特に段間構造や衛星フェアリングのような大規模・複雑形状の構造では、低コスト化と再使用化の要求を満たすために、運用段階での健全性評価を短時間かつ高信頼に実施できる検査基盤が重要となる。一方で、CFRP は層間剥離などの内部損傷が表面観察のみでは把握しにくく、従来の検査手法だけで効率的に健全性を保証することには限界がある [1]。

1.2 非破壊検査の課題

宇宙輸送機器の非破壊検査では、打音検査や超音波測定が広く用いられてきたが、広範囲計測の効率、検査コスト、運用時の迅速性の観点で改善余地がある [1]。これに対して赤外線応力測定は、表面温度変化から表面主応力和分布 (DSPSS) を取得できる非接触計測として有望である [2]。また、DSPSS と機械学習を組み合わせた欠陥推定では、FEM 由来データに基づく逆解析の有効性が示されている [3]。さらに、有限要素メッシュを直接扱うグラフ学習の有効性も報告されている [4]。しかし、先行研究の多くは単純形状試験片を中心とした検証であり、宇宙輸送機器構造への拡張と、シミュレーション学習から実験計測への接続を同時に扱う枠組みは十分に整理されていない [5]。

1.3 目的

そこで本研究では、赤外線応力測定と機械学習を統合し、次の 3 点で既存研究を拡張する。第 1 に、対象を単純積層板中心の設定から宇宙輸送機器構造へ拡張する。第 2 に、FEM 由来 DSPSS による事前学習と実験由来 DSPSS による適応を組み合わせ、シミュレーション・実験間ギャップを低減する。第 3 に、推定精度だけでなく、ノイズ耐性、条件変動への汎化性、実験データとの整合性を評価する。以上により、宇宙輸送機器の非破壊検査に資する実用的な欠陥推定手法の確立を目的とする。

2 理論

本研究では、CFRP 構造のメッシュ表現と応力場情報を同時に扱うため、グラフ学習に基づく欠陥推定を想定する。代表的なグラフ畳み込みの更新は、隣接節点の情

報を集約して節点特徴を更新する構造で表される [6]:

$$z_i^{(l+1)} = \phi \left(\sum_{j \in N(i) \cup \{i\}} \frac{1}{\sqrt{\deg(i) \deg(j)}} W^{(l+1)} z_j^{(l)} \right) \quad (1)$$

ここで、 $z_i^{(l)}$ は節点特徴、 $W^{(l+1)}$ は学習パラメータ、 ϕ は活性化関数である。また、有限要素解析結果の学習にグラフニューラルネットワークが有効であることが示されており、本研究のモデル設計の基盤とする [4]。

3 方法

提案手法は、(i)FEM 由来 DSPSS、(ii) 赤外線応力測定由来 DSPSS、(iii) 欠陥ラベルの 3 要素を統合して学習を行う。まず FEM データを用いて基礎学習を行い、次に赤外線応力測定データを用いて実験条件への適応を行う。この二段階設計により、シミュレーションデータの量的優位性と実験データの現実性を両立する。入力 は表面主応力和分布およびメッシュ関連情報、出力は欠陥位置 (必要に応じて層情報を含む) とする。評価は推定精度に加えて、ノイズ耐性、実験条件変化に対する汎化性、および実験データとの整合性を確認する。

4 今後の予定

短期的には、宇宙輸送機構造を対象にした解析条件の固定と、赤外線応力測定データの前処理手順の確立を行う。次に、FEM 事前学習モデルに対する実験データ適応を実施し、シミュレーション中心推定と実験統合推定の比較評価を進める。最終的には、宇宙輸送機非破壊検査への適用を意識した、実験統合型欠陥推定手法としての妥当性を検証する。

参考文献

- [1] 横野泰和. 非破壊検査の種類と特徴. 溶接学会誌, 59(6):410–413, 1990.
- [2] 阪上隆英. 赤外線サーモグラフィによる熱弾性応力測定 of 最近の進歩. 実験力学, 1(3):120–126, 2001.
- [3] Kojima Y. Hirayama K. Endo K. Hiraide K. Muramatsu M. Inverse estimation method for internal defects based on surface stress of carbon-fiber-reinforced plastics using machine learning. *Advanced Composite Materials*, 31(6):617–629, 2022.
- [4] Horie M. Morita N. Ihara Y. and Mitsume N. Learning mesh-based numerical analysis using graph neural networks. *Transactions of JSCES*, arXiv:2010.03409, 2020.
- [5] 西岡 佳祐. グラフニューラルネットワークを用いた炭素繊維強化プラスチック製穴あき試験片の欠陥推

定手法の開発. 慶應義塾大学 理工学部 機械工学科
2024 年度 卒業論文, 2025.

- [6] Thomas N. Kipf. Max W. Semi-supervised classification with graph convolutional networks. *ICLR*, arXiv:1609.02907, 2017.